



Дисперсионный анализ

Центр биоэлектрических интерфейсов, 13 февраля 2019 г.

Денис Деркач, Влад Белавин

Оглавление

Мотивация

- › ранее, мы рассматривали одно- и двухвыборочные тесты (например, t-test);
- › что делать, если мы хотим сравнить сразу несколько выборок?

Мотивирующий пример







График слева: мы можем сказать, что средние, видимо, отличаются.
Что мы можем сказать про график справа?

Мотивирующий пример

Иными словами, пришли ли семплы из одного распределения или из разных?



Или



Обсуждение мотивирующего примера

- › Эти два случая отличаются так как в первом случае данные внутри семпла не сильно варьируются. Большая дисперсия отражает большую неопределенность в отношении значений истинных неизвестных средних.
- › Необходимо сравнить дисперсию внутри группы с дисперсией между группами, для того, чтобы получить вывод о равенстве средних.

Тестирование гипотез: нулевая гипотеза

Сформулируем нулевую гипотезу:

$$\triangleright H_0: \mu_1 = \mu_2 = \mu_3.$$

Это сложная гипотеза, то есть она содержит в себе много парных и непарных простых (например $\mu_1 = \mu_2$ или $\mu_2 = \frac{\mu_1 + \mu_3}{2}$).

NB: есть другие способы сформулировать нулевую гипотезу ANOVA.

Тестирование гипотез: альтернативная гипотеза

Сформулируем альтернативную гипотезу:

$$> H_1: \mu_1 \neq \mu_2 \text{ или } \mu_2 \neq \mu_3 \text{ или } \mu_1 \neq \mu_3.$$

Заметим, что H_0 отвергается, если верна хотя бы одна из маленьких частных альтернативных гипотез (парных или комплексных).

NB: ANOVA не говорит какая.

Какой тест предпочесть?

Мы можем взять несколько попарных t -тестов, проверяя:

› $H_0: \mu_1 = \mu_2;$

$H_1: \mu_1 \neq \mu_2.$

› $H_0: \mu_2 = \mu_3;$

$H_1: \mu_2 \neq \mu_3.$

› и т.д.

Проблема. вероятность ошибки первого рода резко увеличивается/

TABLE 1: Probability of Committing at Least One Type I Error by Using Two-Sample t Tests for All C Pairwise Comparisons of k Means*

k	C	Level of Significance, α , Used in the t Tests				
		0.10	0.05	0.01	0.005	0.001
2	1	0.10	0.05	0.01	0.005	0.001
3	3	0.27	0.14	0.03	0.015	0.003
4	6	0.47	0.26	0.06	0.030	0.006
5	10	0.65	0.40	0.10	0.049	0.010
6	15	0.79	0.54	0.14	0.072	0.015
10	45	0.99	0.90	0.36	0.202	0.044
	∞	1.00	1.00	1.00	1.000	1.000

*There are $C = k(k - 1)/2$ pairwise comparisons of k means. This is the number of combinations of k items taken two at a time.

Идея ANOVA

- › Заметим, что при верной H_0 все группы получены из популяций с одинаковыми средним μ и дисперсией σ^2 .
- › Давайте оценим дисперсию разными независимыми способами и сравним!
- › Можем оценить исходя из вариативности внутри группы и вариативности между групп.

Вариативность между группами

Оценим σ^2 на основе дисперсии средних между группами (посчитаем ошибку среднего, как будто это выборочные средние, и из неё вычислим дисперсию):

$$s_{\bar{x}} = \frac{\sum_j (\bar{X}_j - \bar{\bar{X}})}{k - 1}$$

Тогда mean square between groups (MS_B):

$$MS_B = \frac{\sum_j (\bar{X}_j - \bar{\bar{X}})n_j}{k - 1}$$

Количество степеней свободы при этом:

$$DF_B = k - 1,$$

где k — число групп.

Вариативность внутри группы

Mean square within groups = error MS

$$MS_W = \frac{s_1^2 + \dots + s_k^2}{k}$$

Количество степеней свободы при этом:

$$DF_B = N - k,$$

где k — число групп, N - полное число семплов.

F-статистика


$$F = \frac{\text{оценка дисперсии между группами}}{\text{оценка дисперсии внутри групп}} = \frac{MS_B}{MS_W}.$$

Тестирование H_0

- › для заданных df рассчитывается критическое значение F ;
- › на основе групп считается F и сравнивается с критическим значением;
- › если F больше критического — H_0 о равенстве средних в группах отвергается;
- › F - это отношение дисперсий, оно имеет особое распределение, оно всегда положительно; ANOVA — принципиально односторонний тест.

F-статистика

$$F = \frac{\text{оценка дисперсии между группами}}{\text{оценка дисперсии внутри групп}} = \frac{MS_B}{MS_W}.$$



Sum of squares

SS - это суммы квадратов отклонений (sum of squared deviations):

- › SS_{Between} - сумма квадратов отклонений каждого среднего в группе от общего среднего = Effect;
- › SS_{Within} — сумма квадратов отклонений каждого измерения от среднего в соответствующей группе = Error;
- › SS_{Total} — сумма квадратов отклонений каждого измерения от общего среднего = Total.

При этом:

$$SS_T = SS_W + SS_B.$$

ANOVA достигнутый эффект

Для того, чтобы понять насколько значим полученный результат в тесте строят два типа переменных:

- › $R^2 = \eta^2 = \frac{SS_B}{SS_T}$, чем выше R^2 , тем больше полученный эффект.
- › $f = \frac{s_{\bar{x}}}{\sqrt{MS_W}}$, чем выше, тем больше полученный эффект.

Переменные ANOVA

Типы переменных:

- › Группирующая переменная, фактор (factor, predictor).
- › Зависимая переменная (dependent variable, response).

Мы пока разбираем случай с одним фактором (one-way). В ANOVA одна зависимая переменная, а факторов может быть несколько, и они могут составлять довольно сложные конструкции.

Дизайн эксперимента

Факторы могут быть двух видов:

- › fixed. Рассматриваются именно эти значения фактора. Другие значения не существуют или не интересуют. Пример: пол, время суток и тд.
- › random. Рассматриваются случайно выбранные значения фактора из многих возможных. За пределами исследования существуют другие значения фактора. Пример: происхождение семпла, процент лекарства.

Для этих типов факторов по-разному оценивается межгрупповая изменчивость. Когда фактор один, это не важно, но в сложных моделях с несколькими факторами эти различия очень важны!

Допущения ANOVA

- › Выборки должны быть случайными, измерения — независимыми.
- › Размеры групп должны различаться как можно меньше.
- › Нормальность в каждой группе по отдельности.
- › Равенство дисперсий в группах.

Требование нормальности

Возможные проверки:

- › Сделать тест по методу моментов (Обычно достаточно проверить эксцесс и асимметрию).
- › Построить гистограмму распределения остатков ($x_i - \bar{x}$) внутри каждого семпла (и проверить goodness-of-fit тесты).
- › Тест Шапиро-Уилка.

Тест Шапиро-Уилка

Критерий Шапиро-Уилка основан на оптимальной линейной несмещённой оценке дисперсии к её обычной оценке методом максимального правдоподобия. Статистика критерия имеет вид:

$$W = \frac{1}{s^2} \left[\sum_{i=1}^n a_{n-i+1} (x_{n-i+1} - x_i) \right]^2 ,$$

где $s^2 = \sum_{i=1}^n (x_i - \bar{x})^2$, $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, а коэффициенты a_{n-i+1} берутся из таблиц.

На практике, следует проверять применимость таблиц в том или ином софте. Можно также использовать тест Шапиро-Франча.

Ненормальные данные

- › Если семплы достаточно большие, можно оставить как есть.
- › Провести преобразование к нормальным:
 - › стандартизовать распределение;
 - › метод Бокса-Кокса.
- › Использовать непараметрический ANOVA:
 - › односторонний дисперсионный анализ Краскела—Уоллиса.

Метод Бокса-Кокса

Для последовательности: $\{y_1, \dots, y_n\}$, $y_i > 0$ однопараметрическое преобразование Бокса-Кокса с параметром λ определяется следующим образом:

$$y_i^\lambda = \begin{cases} \frac{y_i^\lambda - 1}{\lambda}, & \text{if } \lambda \neq 0, \\ \log(y_i), & \text{if } \lambda = 0. \end{cases}$$

Где λ - свободный параметр.

Требование равенства дисперсий

Для проверки можно:

- › Использовать тест Левена (Ливиня).
- › Использовать F-тест.
- › Построить зависимость остатков (residuals) от средних.

Тест Ливиня

Проверяет равенство дисперсий всех семплов.

$$W = \frac{(N - k)}{(k - 1)} \cdot \frac{\sum_{i=1}^k N_i (Z_{i\cdot} - Z_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{N_i} (Z_{ij} - Z_{i\cdot})^2},$$

Здесь Z может центрироваться на:

- › среднее выборки (для симметричных распределений);
- › медиану выборки (для асимметричных распределений);
- › усечённое среднее выборки (для распределений с тяжёлыми хвостами).

В общем случае рекомендуют использовать медиану.

Значение W затем сравнивается с соответствующим F распределением.

Свойства ANOVA

- › Возможно провести one-way ANOVA в случае, если у нас в руках есть только средние значения, показатели разброса (SD, SE, s^2) и размер выборок (например, из какой-нибудь статьи).
- › В случае двух выборок ANOVA эквивалентна t -тесту.

Апостериорные (post-hoc) тесты

ANOVA не называет причину, по которой была отвергнута гипотеза H_0 . Потому используют апостериорные тесты:

- › Сначала сравнить все группы между собой с помощью ANOVA.
- › Если различия есть, использовать методы множественного сравнения (сравнивают группы попарно, сохраняя общую $\alpha = 0.05$).
- › Если различий нет, анализ следует считать завершённым (и не проводить post-hoc тесты).

NB: проведение апостериорных тестов может испортить весь анализ.

Тест Тьюки

Он же honestly significant difference test (HSD test) or wholly significant difference test (WSD test).

- › Выстраиваем средние по выборке по возрастанию.
- › Строим статистику $q = \frac{Y_A - Y_B}{SE}$, где Y - среднее (причём $Y_A > Y_B$, SE - стандартное отклонение.
- › Ищем значимость $q_{\alpha, N-k, k}$ для нужного α .

Тест Тьюки

- › Наиболее распространённый и рекомендуемый в литературе тест;
- › строго контролирует α (0.05);
- › проверяет все парные гипотезы сразу;
- › плохо работает, если размер групп сильно различается;
- › чувствителен к неравенству дисперсий;
- › считает статистику (q) на основе MS_{within} и df .

Другие post-hoc тесты

- › Тьюки-Крамера, решает проблему теста Тьюки для неравных выборок.
- › Критерий Ньюмена-Кейлса. Все средние упорядочивают по возрастанию и пошагово вычисляют статистики; начинают от сравнения наибольшего с наименьшим. Сравнивают с $q_{\alpha, N-k, p}$, где p — диапазон средних. Мощнее теста Тьюки, но плохо контролирует ошибку 1-го рода.
- › Критерий Шеффе (Scheffe test) — очень консервативный, мощность меньше, чем у теста Тьюки (но см. ниже).
- › Критерий Даннетта (Dunnnett test) — используется для сравнения нескольких групп с контрольной группой, мощнее, чем тест Тьюки. Размер контрольной группы рекомендуется делать больше, чем размеры остальных групп в $\sqrt{k-1}$ раз.

Failed post-hoc

Бывает так, что в ANOVA нулевая гипотеза отвергается, а пост-хок тесты не обнаруживают различий, так как их мощность ниже. В этом случае необходимо увеличивать размер выборки.

Анализ контрастов (planned comparisons)

- › Проводится вместо ANOVA.
- › Важно: то, какие группы сравнивать, выбирают заранее, до проведения какого-либо анализа. В идеале — ещё при постановке исследования.
- › В тесте проверяется только одна гипотеза;
- › Можно провести 2-3 таких теста в пределах одного «набора» групп, только надо следить, чтобы сравнения не сильно перекрывались, не были избыточными.
- › Мощнее post-hoc тестов.

Пример

У нас 4 группы тигров, их кормят: овощами; фруктами;рыбой; мясом.

Вопрос: отличается ли масса тигров, питающихся животной и растительной едой?

Построение контрастов

Контраст — линейная комбинация средних значений.

Коэффициенты сравнения — константы, на которые умножены средние. Таким образом гипотезы формулируются:

$$H_0 : \sum_i C_i \mu_i = 0;$$

$$H_1 : \sum_i C_i \mu_i \neq 0.$$

При этом $\sum_i C_i = 0$.

Если тестируется несколько гипотез: $\sum_i C_{1,i} C_{2,i} = 0$. В этом случае статистика строится: $t = \frac{\sum_i C_i \mu_i}{SE}$ и имеет t распределение.

Пример

У нас 4 группы тигров, их кормят: овощами; фруктами; рыбой; мясом.

Вопрос: отличается ли масса тигров, питающихся животной и растительной едой?

Мы строим контраст: $\frac{1}{2}\mu_1 + \frac{1}{2}\mu_2 - \frac{1}{2}\mu_3 - \frac{1}{2}\mu_4$.